

TRƯỜNG ĐẠI HỌC FPT

Môn học: ADY201m



BÁO CÁO ĐỀ TÀI

PHÂN TÍCH VÀ DỰ ĐOÁN GIÁ BẤT ĐỘNG SẢN

Thành viên nhóm:

SE201725	Nguyễn Gia Huy
SE203377	Trần Cảnh Nhật Minh
SE204049	Nguyễn Xuân Bình
SE201652	Đặng Thái Nguyên

Tháng 3 năm 2026

Mục lục

1	Giới thiệu	1
1.1	Mục tiêu Phân tích và Dự đoán	1
2	Thu thập dữ liệu	1
2.1	Dữ liệu bất động sản	1
2.2	Dữ liệu địa lý và tiện ích	1
3	Tổng quan về dữ liệu thô	1
4	Phương pháp xử lý dữ liệu	2
4.1	Làm sạch và Chuẩn hóa dữ liệu	2
4.2	Xử lý dữ liệu thiếu và Chọn lọc đặc trưng	2
5	Kế hoạch thực hiện	3
5.1	Phương pháp làm việc (Mô hình OSEMN)	3
5.2	Phân công nhiệm vụ chi tiết	4
6	Khám phá và Phân tích dữ liệu (EDA)	4
6.1	Phân bố giá trị Bất động sản & Tương quan với Diện tích	4
6.2	Phân hóa giá trị theo khu vực	5
6.3	Ma trận tương quan giữa các biến số	5
7	Xây dựng và Huấn luyện Mô hình	6
7.1	Tiền xử lý (Pipeline)	6
7.2	Đánh giá và Lựa chọn mô hình	6
8	Triển khai Ứng dụng Thực tế	7
9	Kết luận	8

1. Giới thiệu

Thị trường bất động sản giữ vai trò trụ cột trong nền kinh tế nhưng thường chịu tác động phức tạp từ đa chiều yếu tố như vị trí, pháp lý, tiện ích..., khiến việc xác định giá trị thực trở thành thách thức lớn. Dự án này tiếp cận vấn đề bằng cách ứng dụng khoa học dữ liệu để khai thác nguồn thông tin phong phú từ các tin đăng bất động sản. Mục tiêu cốt lõi là định lượng mức độ ảnh hưởng của các thuộc tính then chốt và xây dựng mô hình dự đoán giá tin cậy. Kết quả nghiên cứu được kỳ vọng sẽ cung cấp cơ sở tham chiếu khách quan, hỗ trợ ra quyết định hiệu quả cho các bên tham gia thị trường và góp phần nâng cao tính minh bạch chung.

1.1. Mục tiêu Phân tích và Dự đoán

Phân tích: Tập trung khám phá mối quan hệ giữa giá và các thuộc tính (diện tích, vị trí, tiện ích, pháp lý). Nhóm đánh giá xu hướng phân bố giá theo khu vực và loại hình bất động sản, đồng thời nhận diện các rủi ro pháp lý tiềm ẩn từ dữ liệu tin đăng.

Dự đoán: Xây dựng mô hình dự báo giá dựa trên thông tin đầu vào của người dùng. Kết quả cung cấp mức giá tham khảo để so sánh với giá chào bán, hỗ trợ người mua thương lượng hiệu quả hơn.

2. Thu thập dữ liệu

Để đảm bảo cơ sở dữ liệu phong phú và đa chiều cho mô hình phân tích, nhóm nghiên cứu đã tiến hành tổng hợp dữ liệu từ hai nguồn chính: thông tin giao dịch thị trường và dữ liệu không gian về hạ tầng đô thị.

2.1. Dữ liệu bất động sản

Phạm vi thu thập dữ liệu tập trung vào 4 thị trường sôi động nhất cả nước bao gồm: **Hà Nội, Đà Nẵng, TP. Hồ Chí Minh và Bình Dương**. Việc lựa chọn các khu vực này giúp đảm bảo cỡ mẫu đủ lớn và phản ánh đúng xu hướng chung của thị trường. Nhóm sử dụng các kỹ thuật thu thập dữ liệu tự động (Web Crawling) trên nền tảng *batdongsan.com.vn* để trích xuất các thuộc tính quan trọng như giá bán, diện tích, kết cấu nhà và tình trạng pháp lý.

2.2. Dữ liệu địa lý và tiện ích

Bên cạnh thông tin tin đăng, yếu tố vị trí được định lượng thông qua dữ liệu bản đồ mở **OpenStreetMap (OSM)**. Nhóm ứng dụng các thuật toán tính toán không gian để thống kê mật độ tiện ích thiết yếu (trường học, y tế, thương mại) trong phạm vi bán kính xác định quanh từng bất động sản, từ đó làm giàu thêm thông tin đầu vào cho mô hình dự báo.

3. Tổng quan về dữ liệu thô

Sau quá trình thu thập, bộ dữ liệu thô bao gồm tổng cộng **39 trường dữ liệu**. Do số lượng biến lớn, nhóm phân loại chúng thành 4 nhóm chính để thuận tiện cho việc quản lý trước khi xử lý:

Nhóm dữ liệu	SL Biến	Mô tả các biến đại diện
1. Metadata tin đăng	10 biến	Các thông tin quản lý tin: <i>post_id, url, published_date, seller_name...</i> giúp định danh và lọc tin rác.
2. Vị trí địa lý	9 biến	Các cấp hành chính (<i>province, district, ward...</i>) và tọa độ (<i>latitude, longitude</i>).
3. Đặc điểm Bất động sản	14 biến	Thông tin tài sản: <i>price_total, area, num_floors, num_bedrooms, direction, furniture, legal_status...</i>
4. Tiện ích ngoại khu	6 biến	Số lượng tiện ích từ OSM: <i>num_schools_1km, num_hospitals_2km, num_markets_1km...</i>

Bảng 1: Tổng quan cấu trúc dữ liệu thô (39 cột)

Việc thu thập số lượng lớn các trường dữ liệu ban đầu giúp nhóm có cái nhìn toàn diện, tuy nhiên không phải tất cả đều đóng góp vào bài toán dự đoán giá. Quá trình chọn lọc sẽ được trình bày ở phần tiếp theo.

4. Phương pháp xử lý dữ liệu

Dữ liệu thô thu thập từ môi trường trực tuyến thường chứa nhiều nhiễu, định dạng không đồng nhất và các giá trị khuyết thiếu. Để xây dựng cơ sở dữ liệu tin cậy cho mô hình dự báo, nhóm nghiên cứu đã thực hiện quy trình tiền xử lý nghiêm ngặt nhằm chuẩn hóa và làm sạch thông tin.

4.1. Làm sạch và Chuẩn hóa dữ liệu

Quy trình xử lý tập trung giải quyết các vấn đề về định dạng và tính nhất quán của dữ liệu đầu vào:

- **Chuẩn hóa định dạng:** Các thuộc tính định lượng (giá, diện tích, kích thước) được trích xuất và chuyển đổi từ dạng văn bản sang định dạng số học để phục vụ tính toán.
- **Đồng bộ hóa dữ liệu:** Các thông tin về địa danh hành chính (Quận/Huyện) được quy hoạch về một danh mục thống nhất, loại bỏ các biến thể tên gọi khác nhau do quá trình nhập liệu thủ công.
- **Khử trùng lặp:** Loại bỏ các bản ghi tin đăng trùng lặp để đảm bảo tính duy nhất và độ chính xác của các quan sát trong tập dữ liệu.
- **Lọc phạm vi dữ liệu:** Để đảm bảo tính thực tiễn và tránh nhiễu cho mô hình, nhóm tiến hành lọc và chỉ giữ lại các bất động sản có mức giá dao động từ **500 triệu đến 60 tỷ VNĐ**, đồng thời có diện tích nằm trong khoảng từ **15m² đến 1000m²**.

4.2. Xử lý dữ liệu thiếu và Chọn lọc đặc trưng

Từ tập dữ liệu ban đầu, nhóm tiến hành sàng lọc để tối ưu hóa đầu vào cho mô hình:

- **Xử lý giá trị khuyết thiếu:** Chiến lược điền khuyết được áp dụng linh hoạt dựa trên đặc thù của từng loại hình bất động sản.
- **Trích chọn đặc trưng:** Loại bỏ các biến không mang giá trị dự báo hoặc gây nhiễu. Kết quả cuối cùng giữ lại **17 thuộc tính đặc trưng** quan trọng nhất được trình bày trong bảng dưới đây.

Nhóm biến	STT	Tên biến	Kiểu	Ý nghĩa sử dụng
1. Mục tiêu & Tham chiếu	1	price_total	Int	Biến mục tiêu: Tổng số tiền người bán mong muốn (VND)
	2	price_per_m2	Float	Đơn giá tham chiếu (VND/m ²)
2. Vị trí địa lý	3	province	Category	Tỉnh/Thành phố.
	4	district	Category	Quận/Huyện.
	5	latitude	Float	Vĩ độ.
	6	longitude	Float	Kinh độ.
3. Đặc điểm Bất động sản	7	area	Float	Diện tích sử dụng (m ²).
	8	category	Category	Loại hình (Chung cư...).
	9	legal_status	Category	Pháp lý (Sổ đỏ...).
	10	frontage	Float	Độ rộng mặt tiền (m).
	11	road_width	Float	Độ rộng đường vào (m).
	12	num_bedrooms	Int	Số phòng ngủ.
	13	num_toilets	Int	Số phòng vệ sinh.
	14	num_floors	Int	Số tầng.
4. Tiện ích ngoại khu	15	num_schools_1km	Int	Mật độ trường (bán kính 1km).
	16	num_hospitals_2km	Int	Mật độ y tế (bán kính 2km).
	17	num_markets_1km	Int	Mật độ chợ (bán kính 1km).

Bảng 2: Danh sách 17 biến đặc trưng phân theo nhóm logic

5. Kế hoạch thực hiện

5.1. Phương pháp làm việc (Mô hình OSEMN)

Dự án tuân thủ quy trình OSEMN: **O**btain (Thu thập) → **S**crub (Làm sạch) → **E**xplore (Khám phá) → **M**odel (Mô hình hóa) → **i**nterpret (Diễn giải).



Hình 1: Quy trình phân tích dữ liệu OSEMN

5.2. Phân công nhiệm vụ chi tiết

Giai đoạn	STT	Nội dung công việc	Thành viên
1. Obtain	1	Xác định mục tiêu và tiêu chí dữ liệu.	Cả nhóm
	2	Thu thập dữ liệu (Web Crawling, API).	Cả nhóm
2. Scrub	3	Kiểm tra, xử lý dữ liệu nhiễu và khuyết thiếu.	Huy, Minh
	4	Chuẩn hóa và gộp dataset thống nhất.	Huy, Minh
3. Explore	5	Trực quan hóa (Biểu đồ, Heatmap).	Huy, Nguyên
	6	Phân tích xu hướng và chọn đặc trưng.	Huy, Bình, Nguyên
4. Model	7	Kỹ thuật đặc trưng: Mã hóa, Chia tập.	Bình
	8	Huấn luyện mô hình Machine Learning.	Huy, Bình
	9	Tinh chỉnh tham số (Model Tuning).	Bình
5. iNterpret	10	Đánh giá kết quả mô hình.	Nguyên
	11	Tổng kết, kết luận và viết báo cáo.	Cả nhóm

Bảng 3: Bảng phân công nhiệm vụ theo 5 giai đoạn OSEMN


6. Khám phá và Phân tích dữ liệu (EDA)

Nhằm hiểu rõ đặc tính dữ liệu và tối ưu hóa không gian báo cáo, nhóm tập trung trình bày 3 phát hiện quan trọng nhất có ảnh hưởng trực tiếp đến việc xây dựng mô hình dự đoán.


6.1. Phân bố giá trị Bất động sản & Tương quan với Diện tích

Qua biểu đồ phân bố tổng giá trị bất động sản, có thể thấy dữ liệu mang đặc trưng phân phối lệch phải (right-skewed) rõ rệt. Phần lớn các tin đăng tập trung đông đúc nhất ở phân khúc giá từ 1 đến 10 tỷ VNĐ. Số lượng bất động sản giảm dần khi mức giá tăng lên. Các tài sản thuộc phân khúc cao cấp chiếm tỷ trọng rất nhỏ. Nhóm đã thiết lập giới hạn mức giá quan sát tối đa ở ngưỡng 60 tỷ VNĐ để loại bỏ nhiễu.

Diện tích là đặc trưng có trọng số ảnh hưởng lớn nhất. Biểu đồ phân tán (Scatter plot) cho thấy mối tương quan thuận rõ rệt: Diện tích càng lớn, tổng giá trị tài sản càng cao. Nhóm đã tiến hành lọc bỏ các điểm dữ liệu dị biệt (diện tích quá lớn nhưng giá quá rẻ hoặc ngược lại) để đảm bảo chất lượng đầu vào cho mô hình.




Hình 2: Phân phối tổng giá trị (Tỷ VNĐ)



Hình 3: Tương quan giữa Diện tích và Giá

6.2. Phân hóa giá trị theo khu vực

Dữ liệu thể hiện sự phân hóa rõ rệt về mặt bằng giá giữa 4 khu vực. TP. Hồ Chí Minh và Hà Nội có mức giá trung bình cao nhất và biên độ dao động lớn. Ngược lại, Bình Dương và Đà Nẵng tập trung ở phân khúc giá ổn định hơn. Điều này khẳng định biến province và district là các biến phân loại (categorical) cực kỳ quan trọng trong mô hình.




Hình 4: Mức giá trung bình phân theo khu vực

6.3. Ma trận tương quan giữa các biến số

Để định lượng mối liên hệ giữa các đặc trưng số, nhóm sử dụng ma trận tương quan (Heatmap). Ma trận này giúp xác định những yếu tố nào có tác động mạnh nhất đến giá trị bất động sản, đồng thời kiểm tra sự nhất quán của tập dữ liệu.

Các chỉ số trên ma trận cho thấy tổng giá (price_total) có mối tương quan thuận rõ rệt với ba yếu tố chính: Diện tích (area - 0.32), Số tầng (num_floors - 0.33) và mật độ chợ/siêu thị trong bán kính 1km (num_markets_1km - 0.31). Kết quả này phản ánh thực tế thị trường: nhà có quy mô xây dựng lớn và nằm gần các khu vực giao thương sầm uất sẽ có giá trị cao hơn.

Ngoài ra, ma trận cũng chỉ ra sự đồng bộ trong kết cấu nhà ở và sự tập trung của hạ tầng tiện ích xã hội (số lượng trường học và bệnh viện tương quan mạnh ở mức 0.80). Việc các biến số này có mối liên hệ mật thiết với nhau giúp mô hình học máy dễ dàng nhận diện và học được các quy luật của dữ liệu.



Hình 5: Ma trận tương quan (Heatmap) giữa 12 đặc trưng số

7. Xây dựng và Huấn luyện Mô hình

7.1. Tiền xử lý (Pipeline)

Nhóm xây dựng Pipeline xử lý dữ liệu tự động bằng *scikit-learn*: Điền giá trị thiếu (Imputer), mã hóa biến phân loại (One-Hot Encoder) và chuẩn hóa thang đo biến định lượng (StandardScaler). Dữ liệu được chia thành tập Huấn luyện và Kiểm thử theo tỷ lệ **80:20**.

7.2. Đánh giá và Lựa chọn mô hình

Nhóm đã tiến hành huấn luyện thực nghiệm 15 thuật toán Học máy khác nhau (từ các mô hình tuyến tính truyền thống đến các thuật toán Ensemble tiên tiến). Hiệu suất được đánh giá qua 3 chỉ số: R^2 (Độ phù hợp), RMSE và MAE (Sai số trung bình).

BẢNG SO SÁNH KẾT QUẢ CÁC MÔ HÌNH (SẮP XẾP TỪ TỐT NHẤT ĐẾN TỆ NHẤT):

	Model	R-squared (R ²)	RMSE (Tỷ VNĐ)	MAE (Tỷ VNĐ)
0	Extra Trees	0.848608	4.016815	2.089744
1	CatBoost	0.845282	4.060707	2.322291
2	Random Forest	0.843933	4.078370	2.157832
3	XGBoost	0.843047	4.089936	2.326198
4	LightGBM	0.831225	4.241160	2.418388
5	Neural Network (MLP)	0.768947	4.962345	2.774025
6	Gradient Boosting	0.762728	5.028680	3.036464
7	SVR (Support Vector)	0.724651	5.417171	2.898606
8	KNN Regressor	0.695713	5.694725	3.076254
9	Decision Tree	0.649089	6.115467	3.045548
10	Linear Regression	0.573204	6.744370	4.512717
11	Ridge Regression	0.572382	6.750859	4.518957
12	Lasso Regression	0.505635	7.258633	4.770522
13	AdaBoost	0.504767	7.264999	5.524347
14	ElasticNet	0.498149	7.313385	4.743450

Hình 6: Bảng xếp hạng hiệu suất của 15 mô hình học máy

Nhận xét và Quyết định: Dựa vào bảng kết quả trên, các thuật toán Tree-based (dựa trên cây quyết định) tỏ ra vượt trội. Trong đó, **Extra Trees (Extremely Randomized Trees)** là mô hình dẫn đầu với chỉ số R^2 cao nhất và sai số MAE, RMSE thấp nhất trong tất cả các mô hình được thử nghiệm.

Do đó, **nhóm quyết định lựa chọn Extra Trees** làm mô hình cuối cùng và tích hợp vào hệ thống Web. Thuật toán Extra Trees không chỉ mang lại độ chính xác cao nhờ việc kết hợp nhiều cây quyết định độc lập, mà còn giảm thiểu hiệu quả hiện tượng quá khớp (overfitting) nhờ cơ chế chọn điểm chia ngẫu nhiên, giúp mô hình hoạt động ổn định và tin cậy trên dữ liệu thực tế.

8. Triển khai Ứng dụng Thực tế

Để hiện thực hóa giá trị của mô hình, nhóm đã sử dụng framework **Streamlit** xây dựng một ứng dụng Web tương tác.

Giao diện "**Dự đoán giá**" được tích hợp bản đồ thông minh (Folium). Khi người dùng click chọn vị trí trên bản đồ, hệ thống API (*Nominatim* và *Overpass*) sẽ tự động quét tọa độ, nội suy địa chỉ hành chính và đếm số lượng tiện ích (trường học, siêu thị, bệnh viện) xung quanh. Kết hợp với mô hình Extra Trees ở backend, ứng dụng lập tức trả về mức giá dự kiến (Tỷ VNĐ) với độ chính xác cao.

Menu

Tổng quan thị trường

Dự đoán giá

Bước 2: Nhập các thông tin chi tiết khác

Deploy

1. Hành chính & Pháp lý

Tỉnh/Thành phố

Hồ Chí Minh

Quận/Huyện

Thành phố Thủ Đức

Loại BĐS

Nhà riêng

Pháp lý

Sổ đỏ/ Sổ hồng

2. Thông số kỹ thuật

Diện tích (m²)

80.00

Mặt tiền (m)

5.00

Đường vào (m)

6.00

Số tầng

1

Số phòng ngủ

2

Số Toilet

2

3. Vị trí & Tiện ích (Auto AI)

Tọa độ Latitude

10.845029

Tọa độ Longitude

106.731359

Trường học (bán kính 1km)

13

Chợ/suối thị (bán kính 1km)

12

Bệnh viện (bán kính 2km)

0

BẮT ĐẦU DỰ ĐOÁN GIÁ

KẾT QUẢ DỰ ĐOÁN:

6.27 Tỷ VNĐ

(Tương đương khoảng: 6,271,000,000 VNĐ)

Hình 7: Giao diện Web App tích hợp bản đồ định giá Bất động sản AI

9. Kết luận

Dự án đã thực hiện thành công quy trình phân tích dữ liệu chuyên sâu trên hàng vạn tin đăng bất động sản tại 4 tỉnh thành lớn. Việc lựa chọn và tinh chỉnh thuật toán **Extra Trees** đã mang lại một mô hình dự báo cực kỳ mạnh mẽ, có khả năng giải thích tốt sự biến động của giá nhà dựa trên diện tích, vị trí và tiện ích.

Thành quả cuối cùng – ứng dụng Web định giá tích hợp bản đồ thông minh – không chỉ chứng minh tính ứng dụng của khoa học dữ liệu trong việc minh bạch hóa thị trường bất động sản, mà còn cung cấp một công cụ tham khảo trực quan, đắc lực cho cả người mua, người bán và giới đầu tư.